

Modelo Vetorial vs. BM25 na coleção Cranfield: pré-processamento, parâmetros e análise de erros

Ana Paula de Abreu Batista (nº USP 12688424)

Italo Carlos Martins Bresciani (nº USP 15461782)

Instituto de Ciências Matemáticas e de Computação (ICMC), Universidade de São Paulo (USP), São Carlos – SP

italo.carlos@usp.br, anapbatista@usp.br

SCC0282 – Recuperação de Informação – Trabalho Prático 1 – 2º semestre de 2026

1 Introdução

Sistemas de recuperação de informação ordenam documentos pela relevância estimada para a necessidade expressa em uma consulta. Os modelos clássicos de casamento de termos, o Modelo Vetorial e o modelo probabilístico BM25, continuam sendo referências importantes, e entender por que eles acertam ou erram em cada consulta ajuda a interpretar seu comportamento [1]. Este trabalho implementa os dois modelos sobre a coleção Cranfield e os compara quantitativa e qualitativamente. Os objetivos são: medir o efeito do pré-processamento; comparar os modelos consulta a consulta; avaliar a sensibilidade do BM25 aos parâmetros k_1 e b ; testar reformulações de consultas; e investigar erros. Os resultados são relacionados a conceitos como frequência de termos, saturação, normalização por comprimento e descompasso vocabular. O código está no notebook `trabalho_pratico_recinfo.ipynb`, e os resultados por consulta, na pasta `resultados/`.

2 Técnicas Utilizadas

2.1 Pré-processamento

Os textos são convertidos para minúsculas e tokenizados com a expressão regular `\w+` (`RegexpTokenizer` do NLTK), que descarta a pontuação e separa palavras compostas. Sobre os tokens, aplicamos opcionalmente a remoção de stopwords (lista em inglês do NLTK) e o stemming de Porter [4]. Isso gera quatro configurações: `basico` (nenhum dos dois pré-processamentos), somente `stopwords`, somente `stemming` e `both` (ambos). O mesmo pré-processamento é aplicado a documentos e consultas. Os documentos são indexados como título + texto. Como o campo de texto do Cranfield já começa repetindo o título (1.398 dos 1.400 documentos), isso na prática duplica o título e dá mais peso aos seus termos. A opção de mantermos essa configuração mostrou que isso melhorou os dois modelos, conforme Seção 4.1.

2.2 Modelo Vetorial

Documentos e consultas são vetores no espaço do vocabulário, com pesos TF-IDF calculados pelo `TfidfVectorizer` do `scikit-learn` [6], com os parâmetros explícitos `smooth_idf=True`, `sublinear_tf=False` e `norm='l2'`:

$$w_{t,d} = tf_{t,d} \cdot idf_t, \quad idf_t = \ln \frac{1 + N}{1 + df_t} + 1, \quad \text{sim}(q, d) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \|\vec{d}\|} = \sum_t \hat{q}_t \hat{d}_t,$$

onde $tf_{t,d}$ é a contagem bruta do termo, $N = 1400$ e df_t é o número de documentos que contêm o termo. O vocabulário e o IDF são aprendidos só nos documentos, e a consulta é projetada no mesmo espaço (`transform`). Como o tf não é saturado, o peso cresce linearmente com a repetição. Já a normalização L2 faz o score depender do quanto os termos da consulta dominam o vetor do documento, e não do tamanho absoluto dele. Pelo “+1” fora do logaritmo, até um termo presente em todos os documentos tem $idf = 1$.

2.2.1 Variante sublinear do tf

Testamos também a variante logarítmica $tf_{t,d} = 1 + \ln f_{t,d}$ para $f_{t,d} > 0$ (`sublinear_tf=True`), que satura a repetição de termos de forma parecida com o que o k_1 faz no BM25. Com `both`, o MAP do Modelo Vetorial sobe de 0,3075 para 0,3098 (+0,8%), o $R@10$ de 0,402 para 0,415 (+3,1%) e o $NDCG@10$ de 0,367 para 0,373 (+1,6%), mas a $P@10$ (−0,2%) e o MRR (−0,7%) pioram; nas outras configurações o ganho de MAP fica entre +1,4% e +2,3%. Por consulta o resultado é quase um empate: a variante é melhor em 109 consultas, pior em 102 e igual em 14, e o ganho de AP não é estatisticamente significativo (teste t pareado $p = 0,65$; Wilcoxon $p = 0,67$). Como a diferença não se sustenta, mantivemos `sublinear_tf=False`: não compensa acrescentar um logaritmo por termo ao cálculo dos pesos. O experimento está em `trabalho_pratico_recinfo_copy.ipynb`, com as saídas em `resultados_sublinear/`.

2.3 Modelo probabilístico BM25

O BM25 [2] foi implementado manualmente na classe `BM25Modelo`, sem bibliotecas de ranking. O construtor pré-calcula a frequência de cada termo em cada documento, o comprimento $|d|$ de cada documento, a média $avgdl$ e o IDF de cada termo. O score é

$$\text{score}(q, d) = \sum_{t \in q} IDF(t) \frac{f_{t,d} (k_1 + 1)}{f_{t,d} + k_1 \left(1 - b + b \frac{|d|}{avgdl}\right)}, \quad IDF(t) = \ln \left(\frac{N - df_t + 0,5}{df_t + 0,5} + 1 \right).$$

O IDF com “+1” (variante do Lucene) nunca é negativo. k_1 controla a saturação da frequência do termo no documento (com $k_1 \rightarrow 0$ o modelo fica binário), e b controla a normalização pelo comprimento ($b = 0$: nenhuma; $b = 1$: total). A soma percorre os tokens da consulta com repetição, então um termo repetido na consulta conta em dobro, e não há saturação da frequência na consulta (parâmetro k_3). Na comparação principal usamos $k_1 = 1,5$ e $b = 0,75$, valores usuais na literatura. Nos dois modelos, documentos com score zero ficam fora do ranking.

3 Avaliação

Usamos a coleção Cranfield, obtida com a biblioteca `ir_datasets` [5], que baixa o arquivo original da Universidade de Glasgow: 1.400 resumos de artigos de aeronáutica, 225 consultas e 1.837 julgamentos, os mesmos em todos os experimentos. Os graus dos julgamentos se distribuem em -1 (225), 1 (128), 2 (387), 3 (734) e 4 (363). Na escala de Cleverdon [3], registrada no arquivo `cranqrel.readme` da coleção, 1 significa “resposta completa” e 4, “interesse mínimo”. A documentação do `ir_datasets` descreve a ordem inversa, mas a biblioteca repassa os valores originais sem transformá-los, e por isso seguimos o `readme`.

Relevância. Para $P@10$, $R@10$, $F1@10$, MAP e MRR, é relevante todo documento com grau ≥ 1 , e julgamentos -1 e documentos não julgados são não relevantes. Todas as 225 consultas têm ao menos um relevante. No $NDCG@10$ usamos relevância graduada com ganho $g = 5 - \text{grau}$ (grau 1 $\rightarrow$ ganho 4), respeitando a escala original. Há exatamente um julgamento -1 por consulta, em geral um documento muito próximo dela: no BM25, ele está no Top 10 em 72% das consultas, e o da consulta 1, por exemplo, é *similarity laws for aerothermoelastic testing*. O padrão é consistente com a metodologia do Cranfield II, em que autores formularam perguntas a partir dos próprios artigos [3]. Tudo indica que o documento -1 é o *artigo-fonte* da pergunta. Seguimos a especificação e o tratamos como não relevante, mas o destacamos na análise (marcado com *).

Métricas. $P@10$ e $R@10$; $F1@10$ (média harmônica das duas); AP calculada sobre o ranking completo e dividida pelo total de relevantes da consulta, com o MAP como sua média; MRR; e $NDCG@10$. Todas são guardadas por consulta (CSVs em `resultados/`) e agregadas pela média sobre as 225 consultas.

Configurações. (i) 4 pré-processamentos $\times$ 2 modelos (BM25 com $k_1 = 1,5$, $b = 0,75$); (ii) comparação por consulta e análise de casos com *both*; (iii) grade $k_1 \in \{0,5; 1,2; 2,0\} \times b \in \{0; 0,75; 1\}$ com *both*, comparada por MAP, $P@10$ e $NDCG@10$; (iv) modificação de consultas e análise de erros com *both* e a melhor combinação da grade ($k_1 = 2,0$, $b = 0,75$). Os qrels são usados só para avaliar, nunca para alterar rankings. Como o melhor pré-processamento e os melhores parâmetros são escolhidos pelo MAP nas mesmas consultas avaliadas, os números da etapa (iv) são levemente otimistas.

4 Resultados Obtidos e Análise

Tabela 1: Métricas médias nas 225 consultas, por pré-processamento e modelo (BM25 com $k_1 = 1,5$, $b = 0,75$).

Pré-processamento	Modelo	$P@10$	$R@10$	$F1@10$	MAP	MRR	$NDCG@10$
basico	Vetorial	0,227	0,371	0,254	0,278	0,505	0,341
	BM25	0,230	0,388	0,261	0,282	0,506	0,349
stopwords	Vetorial	0,224	0,370	0,252	0,284	0,516	0,341
	BM25	0,237	0,401	0,270	0,296	0,529	0,366
stemming	Vetorial	0,234	0,385	0,262	0,298	0,516	0,355
	BM25	0,237	0,397	0,268	0,307	0,535	0,371
both	Vetorial	0,243	0,402	0,273	0,307	0,534	0,367
	BM25	0,243	0,407	0,275	0,319	0,551	0,380

4.1 Influência do Pré-processamento

A configuração *both* é a melhor nos dois modelos (Tabela 1). Em relação a *basico*, o MAP sobe 13% no BM25 (0,282 $\rightarrow$ 0,319) e 11% no Vetorial (0,278 $\rightarrow$ 0,307). O stemming sozinho contribui mais que a remoção de stopwords sozinha: MAP de 0,307 contra 0,296 no BM25, e de 0,298 contra 0,284 no Vetorial. O Porter reduz o vocabulário de 7.471 para 4.820 termos, agrupando variantes (*heated/heating* $\rightarrow$ *heat*), o que aumenta os casamentos entre consulta e documento. Mas ele não agrupa *theory/theoretical* (*theoril/theoret*) nem *sudden/suddenly*, falhas que reaparecem na análise de erros. A remoção de stopwords ajuda porque as consultas são perguntas (38,6% dos seus tokens são stopwords) e algumas stopwords têm IDF alto no corpus: *what* ocorre em só 16 resumos (idf 5,41 no TF-IDF) e favorece esses documentos sem motivo. No TF-IDF, o “+1” do IDF também mantém *the* e *of* com peso ≈ 1 , e essas palavras inflam a norma dos vetores (as stopwords são 41% dos tokens dos documentos). O ganho não é uniforme: no BM25, *both* supera *basico* em 139 consultas e perde em 75. Por fim, indexar só o texto (título 1 $\times$) em vez de título + texto (título 2 $\times$) reduz o MAP de 0,319 para 0,307 no BM25 e de 0,307 para 0,294 no Vetorial. Dobrar a frequência dos termos do título, que resumem o assunto central, funciona como um reforço de peso.

4.2 Comparação entre o Modelo Vetorial e o BM25

Com *both*, o BM25 é ligeiramente melhor na média (MAP 0,319 contra 0,307; MRR 0,551 contra 0,534; NDCG@10 0,380 contra 0,367), e a P@10 é idêntica (0,243). A média, porém, esconde diferenças grandes nos dois sentidos (Figura 1). O BM25 tem AP maior em 121 consultas, o Vetorial em 96, há 8 empates, e 52 consultas têm $|\Delta AP| > 0,1$. A Tabela 2 mostra os casos extremos pedidos na especificação. A análise a seguir decompõe os scores por termo (função *decompor_scores* do notebook); “Qn” indica a consulta n.




Figura 1: Diferença de AP (BM25 – Vetorial) por consulta, com pré-processamento *both*. As consultas das pontas são analisadas na Seção 4.3.

Tabela 2: Top 5 de cada modelo nos casos analisados (*both*; BM25 com $k_1 = 1,5$, $b = 0,75$). Documentos relevantes em **negrito**; * = documento-fonte (julgamento –1).

Caso	Q	AP Vet.	AP BM25	Top 5 Vetorial	Top 5 BM25
BM25 melhor	36	0,064	0,502	398, 303, 564, 554, 623	168 , 623, 123, 518 [†] , 550
	173	0,583	1,000	532 [†] , 367 , 451 , 917, 1073	367 , 451 , 532 [†] , 917, 767
Vetorial melhor	17	0,508	0,107	106 , 1281, 700, 1301, 498 [†]	1108, 1281, 700, 336, 106
	95	0,750	0,450	662 , 635 [†] , 1258, 283 , 1191	635 [†] , 662 , 1002, 553, 283
Ambos ruins	13	0,000	0,000	496 [†] , 643, 199, 313, 903	496 [†] , 903, 313, 520, 440
	22	0,000	0,000	125, 254, 413, 165, 560	125, 560, 413, 50, 348

4.3 Análise por consulta

Q36 (*relaxation effects on gaseous heat transfer to a suddenly heated wall*; BM25 melhor). O relevante 168 é o único do topo que contém *relax*, o termo mais raro da consulta ($df = 27$). O termo aparece 5 vezes e, sozinho, rende 7,04 pontos no BM25, que põe o documento em 1º. No Vetorial ele fica em 8º: com tf bruto, o cosseno favorece documentos curtos que repetem termos comuns da consulta, como o doc 398 (40 tokens, *heat* e *transfer* com $tf = 4$), 1º colocado. No BM25, *heat* com $tf = 6$ (doc 303) rende 6,46 pontos, contra 3,82 com $tf = 2$: a saturação limita o ganho da repetição e deixa o termo raro decidir. O outro relevante, o doc 169 (*on the sudden contact between a hot gas and a cold solid*), só compartilha *heat* com a consulta. *Suddenly* vira *suddenli* e não casa com *sudden*, e *hot/cold* não casam com *heated*.

Q173 (*lyapunov's method on the stability of linear differential equations*; BM25 melhor). A diferença vem só da posição do documento-fonte 532, curto (41 tokens) e com *lyapunov* ($df = 2$) 4 vezes. No cosseno, esse único termo rende 0,372 e o põe em 1º. No BM25, a saturação deixa esse $tf = 4$ (13,12 pontos) quase empatado com o $tf = 3$ do relevante 367 (11,35), que casa 6 termos da consulta, contra 3 do 532: a *cobertura* decide. O relevante 451 grafia *liapunov*, nunca casa com *lyapunov* e chega ao topo pelos outros termos.

Q17 (*three-dimensional problem of a transverse potential flow about a body of revolution*; Vetorial melhor). O relevante 106 é curto (43 tokens) e concentra os termos raros *transvers*, *potenti* e *revolut*, o que o põe em 1º no Vetorial. No BM25 ele cai para 5º, atrás do doc 1108 (154 tokens), que casa 7 termos distintos, entre eles *dimension* e *problem*, repetidos na consulta. O BM25 soma contribuições saturadas de muitos termos e favorece a cobertura. No cosseno, a norma de um documento longo se espalha por muitos termos, e cada casamento pesa menos.

Q95 (*theoretical heat transfer distribution around a hemisphere*; Vetorial melhor). O relevante 662 é longo (241 tokens, $2,3 \times avgdl$) e repete muito os termos da consulta (*heat* $tf = 12$, *transfer* $tf = 9$, *hemispher* $tf = 6$). O cosseno o põe em 1º. No BM25, a saturação limita *heat* a 3,04 pontos e $b = 0,75$ penaliza o comprimento, e o documento-fonte 635 (131 tokens) passa à frente.

Q13 e Q22 (AP zero nos dois modelos). Nenhum dos 4 relevantes da Q13 (*basic mechanism of the transonic aileron buzz*) contém *qualquer* termo da consulta. Eles descrevem o mecanismo físico (interação de ondas de choque, vorticidade, *buffeting*) com outras palavras, então têm score zero e nem entram no ranking. O 1º lugar nos dois modelos é o documento-fonte 496, o único do corpus com *buzz*. Na Q22, o único relevante (doc 68, grau 1, *air-helium simulation and hypersonic*

approximations) também não compartilha nenhum termo com a consulta. É o *descompasso vocabular* total, que nenhum modelo de casamento lexical resolve; seriam necessárias expansão de consulta, *relevance feedback* ou representações semânticas.

Em resumo, o BM25 ganha quando a saturação impede que termos comuns repetidos dominem (Q36) ou quando a cobertura de mais termos importa (Q173). O Vetorial ganha quando o relevante concentra poucos termos raros num texto curto (Q17) ou repete muito os termos da consulta num texto longo (Q95). Os documentos-fonte ficam em 1º lugar em 42% das consultas no BM25 e em 37% no Vetorial, o que pesa nas métricas dos dois modelos.

4.4 Variação dos parâmetros do BM25

Tabela 3: MAP / NDCG@10 do BM25 para cada combinação de k_1 e b (pré-processamento both).

	$b = 0$	$b = 0,75$	$b = 1$
$k_1 = 0,5$	0,278 / 0,333	0,298 / 0,357	0,300 / 0,358
$k_1 = 1,2$	0,291 / 0,346	0,315 / 0,374	0,311 / 0,370
$k_1 = 2,0$	0,299 / 0,359	0,320 / 0,385	0,319 / 0,376

O parâmetro b é o de maior efeito (Tabela 3): para todo k_1 , $b = 0$ é o pior valor. Sem normalização, documentos longos acumulam mais ocorrências dos termos da consulta e dominam o topo. Com $k_1 = 1,2$, o comprimento médio dos documentos do Top 10 é 146,3 tokens com $b = 0$, contra 109,7 com $b = 0,75$ e 101,3 com $b = 1$ (*avgdl* = 102,9; os relevantes têm 106,8 em média). Com $k_1 \geq 1,2$, $b = 1$ fica um pouco abaixo de $b = 0,75$ por penalizar demais relevantes longos: com $k_1 = 1,2$, o doc 662 da Q95 (241 tokens) cai de 2º para 3º, e o AP da consulta vai de 0,450 para 0,367. Com $k_1 = 0,5$ a ordem se inverte, porque a normalização aparece multiplicada por k_1 no denominador e perde força quando k_1 é pequeno.

Quanto a k_1 , valores maiores são melhores para todo b . Com $k_1 = 0,5$ o modelo é quase binário: um termo com $tf = 3$ vale 1,29 vezes um com $tf = 1$, contra 1,8 vezes com $k_1 = 2,0$. No Cranfield a repetição é informativa: os resumos são curtos, um termo repetido costuma ser o assunto central, e o título duplicado garante $tf \geq 2$ aos seus termos (metade dos termos casados no Top 10 tem $tf \geq 3$). O melhor valor está na borda da grade, mas o ganho diminui: +0,017 de 0,5 para 1,2 e +0,005 de 1,2 para 2,0. MAP, P@10 e NDCG@10 ordenam as combinações quase da mesma forma, e a melhor é $k_1 = 2,0$, $b = 0,75$ (P@10 0,248).

Consulta sensível a b . Procuramos a consulta cujo Top 5 mais muda entre $b = 0$ e $b = 1$, com $k_1 = 1,2$. É a Q67 (*can series expansions be found for the boundary layer on a flat plate in a shear flow*), cujos dois Top 5 não têm nenhum documento em comum. Com $b = 0$, o Top 5 tem documentos de 101 a 217 tokens e só um relevante (AP 0,207): trabalhos longos sobre camada-limite e placas planas em geral, que acumulam ocorrências de *boundari*, *layer*, *flow* e *plate*. Com $b = 1$, os cinco são relevantes e têm de 25 a 57 tokens (AP 0,552): notas curtas e específicas sobre escoamento cisalhante sobre placa plana.

4.5 Modificação de consultas

Tabela 4: Consultas modificadas: AP original $\rightarrow$ modificada e, entre parênteses, documentos em comum nos dois Top 10 (BM25 com $k_1 = 2,0$, $b = 0,75$).

Q	Estratégia	Versão modificada	Vetorial	BM25
1	reformulação	<i>dynamic scale similarity laws govern wind tunnel testing...</i>	0,315 $\rightarrow$ 0,242 (6)	0,243 $\rightarrow$ 0,174 (5)
3	mais específica	<i>analytical transient temperature distribution... multilayer...</i>	0,687 $\rightarrow$ 0,678 (9)	0,689 $\rightarrow$ 0,775 (8)
15	sem repetição	<i>mechanical and optical properties of photoelastic specimens</i>	0,667 $\rightarrow$ 1,000 (2)	1,000 $\rightarrow$ 1,000 (3)
95	generalização	<i>...around aerodynamic blunt bodies in hypersonic flow</i>	0,750 $\rightarrow$ 0,313 (1)	0,417 $\rightarrow$ 0,309 (3)
173	sem contexto	<i>lyapunov stability linear differential equations periodic</i>	0,583 $\rightarrow$ 0,500 (8)	0,833 $\rightarrow$ 0,833 (7)

As versões modificadas foram escritas à mão (Tabela 4; os textos completos estão no notebook).

- **Q1:** trocar *models*, *aircraft* e *constructing* por termos de ensaio fez o relevante 51 (*theory of aircraft structural models...*, com *aircraft* 10 vezes) cair do 1º para o 21º lugar no Vetorial e o 22º no BM25. Entraram documentos sobre ensaios em túnel de vento, quase todos não relevantes: um *topic drift*.
- **Q3:** a versão mais específica quase não muda o Top 10, mas no BM25 leva os relevantes 6 e 5 ao 1º e 2º lugares, acima do documento-fonte (AP 0,689 $\rightarrow$ 0,775).
- **Q15:** a original repete *materials*, que ganha peso dobrado e atrai documentos sobre materiais em geral. Sem a repetição, o relevante 463 sobe de 6º para 2º no Vetorial (AP 1,0). No BM25, os dois relevantes já eram 1º e 2º, e só mudaram os não relevantes.
- **Q95:** a generalização removeu o termo mais discriminante (*hemispher*, $df = 31$), e o relevante 662 caiu para 16º no Vetorial e 17º no BM25.
- **Q173:** tirar *references*, *method* e *coefficients* não altera o BM25, mas no Vetorial o relevante 451 cai de 3º para 4º. Como grafa *lyapunov*, ele depende justamente desses termos para casar com a consulta.

Em geral, retirar termos discriminantes ou usados pelos relevantes prejudica, e acrescentar termos específicos presentes nos relevantes ajuda. O Vetorial foi mais sensível: a variação média de $|\Delta AP|$ foi 0,19, contra 0,05 no BM25. Nossa hipótese é que, sem saturação, o cosseno depende de poucos termos muito repetidos, e mexer em um deles reordena mais o ranking.

4.6 Análise de erros

Com o BM25 ($k_1 = 2,0$, $b = 0,75$), 416 documentos não relevantes aparecem no Top 3 das 225 consultas: 130 (31%) são documentos-fonte e 286 não foram julgados. Há também 287 relevantes de grau 1 ou 2 fora do Top 10, dos quais 22 nem são recuperados. Examinamos cinco casos com a decomposição do score por termo.

FP1: doc 486 na Q1 (2º lugar). *Similarity laws for aerothermoelastic testing* casa 7 dos 11 termos da consulta, incluindo os raros *law* ($df = 53$, $tf = 4$) e *aeroelast* ($df = 18$). É o documento-fonte: o mais próximo lexicalmente e, pela construção da coleção, o artigo que originou a pergunta. O “erro” vem da forma como os qrels marcam o artigo-fonte. Como isso afeta 31% dos falsos positivos, reduz sistematicamente a $P@10$, o MAP e o MRR dos dois modelos.

FP2: doc 367 na Q28 (1º lugar). A consulta pede aplicações da *linear theory design of curved wings*, mas o documento trata de projeto de sistemas de controle pelo método de Lyapunov. Ele casa *applic*, *linear* ($tf = 2$), *theori* ($tf = 2$) e *design* ($tf = 3$), todos em outro sentido, sem conter *curv* nem *wing*. É mais curto que a média (74 tokens), então não é penalizado pelo tamanho, e a soma de quatro termos de IDF médio (12,28) supera os documentos sobre asas. O BM25 é *bag-of-words*: não modela o contexto dos termos nem exige os termos que definem o domínio. No Vetorial, o mesmo documento fica só em 27º.

FP3: doc 186 na Q37 (1º lugar). *Base pressure in supersonic flow* discute “the problem of accurately predicting the pressure . . . at the base of bodies”, exatamente o que a consulta pede (*theoretical methods for predicting base pressure*), mas não foi julgado. Os qrels do Cranfield não são exaustivos, e parte dos falsos positivos provavelmente é relevante.

FN1: doc 24 na Q94 (14º lugar, grau 1, resposta completa). *Theory of stagnation point heat transfer in dissociated air* responde à pergunta (*theoretical heat transfer rate at the stagnation point of a blunt body*), mas perde dois termos. *Blunt* não aparece, e *theoretical* (*theoret*) não casa com *theory* (*theori*). Além disso, o documento é longo (154 tokens, $1,5 \times avgdl$), e $b = 0,75$ reduz as contribuições de *stagnat* e *point* ($tf = 5$).

FN2: doc 29 na Q1 (37º lugar, grau 2). O documento descreve “simple models intended to simulate parts . . . of an aircraft structure”, a mesma ideia de semelhança com outras palavras. Sem *similar*, *law* e *aeroelast*, os termos mais discriminantes, ele casa só *model*, *heat* e *aircraft* (score 9,92, contra 25,72 do 1º colocado).

Três padrões aparecem. Documentos-fonte e lacunas de julgamento inflam os falsos positivos sem que o modelo esteja necessariamente errado. Termos genéricos usados em outro sentido geram falsos positivos reais. E o descompasso vocabular e as limitações do stemmer, agravados pela normalização em documentos longos, causam os falsos negativos.

5 Considerações finais

(i) Stopwords + stemming é a melhor configuração nos dois modelos (+13% e +11% de MAP sobre a configuração básica), com o stemming contribuindo mais; duplicar o título também ajuda. (ii) O BM25 é ligeiramente superior na média (MAP 0,319 contra 0,307), mas os modelos divergem muito por consulta. As diferenças se explicam pela saturação do tf , pela cobertura de termos e pela normalização de comprimento. (iii) b é o parâmetro de maior efeito, pois sem normalização os documentos longos dominam o topo. Um k_1 maior ajuda nesta coleção, em que a repetição é informativa, e a melhor combinação da grade foi $k_1 = 2,0$, $b = 0,75$. (iv) O descompasso vocabular e as limitações do stemmer são a principal causa de falsos negativos. Já os documentos-fonte (−1) e os julgamentos incompletos respondem por boa parte dos falsos positivos, o que é uma limitação da própria avaliação. (v) Na reformulação, remover termos discriminantes prejudica e acrescentar termos específicos ajuda, e o Vetorial foi o mais sensível. As limitações do estudo são a escolha de parâmetros e pré-processamento nas mesmas consultas avaliadas e a ausência de testes de significância estatística. Como trabalhos futuros, ficam a expansão de consultas ou o *relevance feedback* contra o descompasso vocabular, a validação cruzada dos parâmetros e os testes estatísticos.

6 Uso de ferramentas de IA

O assistente Claude (Anthropic), via Claude Code, foi usado para três atividades. A primeira foi revisar o notebook frente à especificação e corrigir inconsistências: fórmula do IDF do TF-IDF, justificativa da concatenação título + texto, afirmações sobre repetição de termos na consulta, texto da consulta 3 na etapa de reformulação e valor de k_1 fora da grade. A segunda foi implementar análises complementares: decomposição dos scores por termo, análise dos documentos −1, ablação do título e gráfico de ΔAP . A terceira foi auxiliar a escrita do README e deste relatório.

Referências

- [1] C. D. Manning, P. Raghavan, H. Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [2] S. Robertson, H. Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.
- [3] C. W. Cleverdon. The Cranfield tests on index language devices. *Aslib Proceedings*, 19(6):173–194, 1967.

- [4] M. F. Porter. An algorithm for suffix stripping. *Program*, 14(3):130–137, 1980.
- [5] S. MacAvaney et al. Simplified Data Wrangling with `ir_datasets`. In *Proc. SIGIR*, 2021.
- [6] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.